

論文①「自然言語から物理動作へ」

完成に向けた実験計画（改訂版）

法政大学データサイエンスセンター長 児玉靖司

2026 年 9 月 29 日

要旨

2026 年 9 月 24 日の計画書を、9 月 29 日までの実機実験の結果に合わせて改訂する。実機 (DOFBOT + Ximu) は、同じ AIPL プログラムで模型と実機の両方を動かし、色の異なる立方体を挟んで置き場へ運ぶ作業を 2 回完遂した。しかし成功率はまだ測っておらず、主実験（事前選別なし A / あり B の対応比較）に必要な実機側の Actor 契約、投入ゲート、実行履歴の記録形式、採点器は未着手である。本書は、残る 5 週間半（9 月 30 日～11 月 6 日）で主実験を成立させるための実験の並びと日程、実機の稼働時間の見積もり、撤退線、および先生に決めていただく事項を示す。数値のうち実測したものと見積もりは区別して書く。

1 到達点（2026 年 9 月 29 日）

表 1: 論文①の研究課題ごとの到達点

項目	状態	論文
RQ1 生成	未見の指示 30 件で予備実験済み（生成プログラム 27 件）	7.1 節
RQ3 検証段	運動学 (Tier-1) と剛体接触 (Tier-2, MuJoCo) で 27 件を実行。Tier-1 の誤った合格 4 件を検出	7.2 節
RQ2 両実行 実機の把持	同じ手順を模型と実機で実行。応答の欠落 22.5%、狭い可達域 色で振り分ける作業を 20 回実行し、最後の 2 回（青・緑）で完遂。模型が見逃した 差を 8 つ同定	7.3 節 7.4 節
RQ4 主実験	未実施（契約・ゲート・記録・採点器が無い）	—

実機で確かめた道具。次は実機で動いており、主実験の部品として使える。

- 手首カメラで立方体を探す手順（撮る → 色の塊の重心を卓上へ逆射影 → 向け直す）。
- 指の軸を合わせて段階的に下ろす手順（撮る姿勢と挟む姿勢を分ける）。
- 挟めたかの判定：指令 135 で閉じた後のサーボ 6 の読み戻しが 133 以下なら挟んでいる。7 回判定し、目視と矛盾した判定は無かった（挟めた 2 回はいずれも目視で確認）。ただし余裕は 0（2 回とも 133）。
- 寸法の一元管理（geometry.json、出典つき）。CG、逆運動学、逆射影が同じ値を読む。
- 実行中の手を表示する PLAN（模型・実機・カメラ系の命令を一つの列に）。

2 9 月 24 日の計画からの遅れ

W0 が 4 日遅れ、W1 が手つかずである。残りは 5 週間半であり、主実験の週（10/19–25）を動かさないために、W1 と W2 の内容を圧縮して再配置する（第 6 節）。

3 今回分かったことが計画に与える影響

- 可達域は土台の軸から 14–23 cm の帯に限られる（指を 8.3 cm とした場合）。課題の配置は、この帯の中に置き場と物体を並べる座標表として作る。三段目の積み重ねは机上のどこでも届

表 2: 旧計画の週と実際

旧計画	予定	実際（9 月 29 日）
W0（9/24-27）	既知座標で把持 20 回、成功率 ≥ 0.8	把持は 2 回成功。 成功率は未測定
W1（9/28-10/4）	共通 Actor 契約（実機側）、投入ゲート、記録形式、E0	未着手。代わりに寸法・指・カメラの実測と探索手順を作った
W2 以降	Tier-2、課題集合、採点器	Tier-2 は前倒しで完了。課題集合・採点器は未着手

かない（7.3 節）。届かない指示を課題集合に意図的に含めれば、Tier-1 の正しい却下を測れる。

2. **Tier-2 の模型が実機の実測に合っていない。** Tier-2 (harness/tier2) は、把持点を掌から 6 cm、指の開きを約 4.2 cm（開き切り）から約 0.2 cm の直動とし、立方体を 1 辺 3.1 cm、手首カメラを指の横（縦の画角 56°）に置いて作られている。実機では指は約 8.3 cm（推定）、開きは 7 段の実測表（開き切りで 6.2 cm、指令 135 で 2.8 cm）、立方体は 3 cm、カメラは手首の上面にある。CG と色判定の係の模型も、Tier-2 とはカメラの位置が異なる。このままではシミュレーションの判定が実機の成否を予測するはずがない。**Tier-2 を geometry.json から組み立て直す**ことを主実験の前提とする。
3. **論文の記述に誤りが一つ残っている。** 7.2 節は Tier-2 のリンク長を「実機の実測値」としているが、公開 URDF の値である（7.4 節と装置の段落は 9 月 29 日に訂正済み）。投稿前に直す。
4. **腕の基板が数分の動作で止まる（4 回）。** Xinu 側の自動リセットが引き金である疑いが濃い。Mac 側の読み取り制限の後の 2 回の実行では止まっていないが、2 回では確かめたことにならない。主実験の 240 回前後の実機実行に耐えるには、system/arm.c の自動リセットを外して焼き直す必要がある。
5. **挟めたかの判定には余裕が無い。** 成功 2 回の読み戻しがしきい値と等しい。しきい値を 134 に上げるか、挟む指令を立方体の幅に合わせて選び直し、成功と失敗の読み戻しの分布を 30 回で測る。
6. **卓上の他の色の物を立方体と取り違える。** 主実験の机上には、立方体と置き場以外の色の物を置かない。これは運用の規則として論文に書く。
7. **ブラウザが板の HTTP を止める。** 主実験中はシミュレータの画面を開かないか、板へ直接つながない構成にする（カメラ画像は係が取得する）。

4 実験の一覧（改訂）

表 3: 実験の並び。E0' を新設し、主実験の前に置く

名称	内容	状態
E0'	実機の基礎性能	新設
E0	計器の検証	未着手
E1	主実験 A/B	未着手
E2	生成の正しさ	一部済
E3	却下の分類	E1 待ち
E4	誤った合格	E1 待ち
E6	人手確認済み	一部済
E5	修正ループ	保留

E0' の合格条件。 把持成功率 ≥ 0.8 (30 回中 24 回以上)、かつ 30 回の間に腕の基板が止まらないこと。成功率が 0.5 未満なら第 7 節の撤退線に移る。0.5 以上 0.8 未満なら、失敗を分類して一つだけ直し、もう 30 回行う。**結果を見てから合格条件を変えない。**

5 試行数と実機の稼働時間

検出力の計算（9 月 24 日の計画書）は変えない。McNemar 正確検定で検出力 0.8 を得るには、効果 0.25 で 62 件が要る。**異なる指示 60 件 × 配置 2 通り**を計画値とし、指示単位のクラスター・ブートストラップで解析する。

表 4: 実機の実行回数と稼働時間の見積もり（1 回 3 分は見積もりであり実測ではない）

実験	実機の実行	時間	備考
E0'	30–60	1.5–3 h	追加の 30 回を含む
E0	30	1.5 h	採点器の一致確認
予備（10 指示 ×2 配置 ×A/B）	≤ 40	≤ 2 h	本実験に入れない
E1（60 指示 ×2 配置）	A 120 + B ≤ 120	≤ 12 h	配置の戻しと較正を含まない
計	≤ 250	≤ 18.5 h	3 時間の実機セッション 7 回前後

各セッションには、安全確認と目視判定のために操作者が一人つく。9 月 28–29 日の実行では、1 回の実行で試行を 6 回繰り返した例があり（20 回目）、そのときは 3 分を超えている。E0' で 1 回の実行時間を実測し、この表を引き直す。

6 日程（9 月 30 日～ 11 月 6 日）

W1：9 月 30 日（火）～ 10 月 4 日（日）—実機を主実験に耐える状態にする

1. Xinu：system/arm.c の自動リセットを外す。あわせて d4eac11 で消えたファンの温度追従と、動かない起動時の仕事（アクター載せ・カメラ開始）を直す。焼いて、冷起動 3 回で version と HTTP を確認する。
2. 仮置き寸法を物差しで測る：指の長さ、手首からカメラ中心まで、指の軸からカメラ中心まで、台座の高さ。画角は、既知の大きさの立方体を既知の距離で撮って求める。geometry.json を「実測」に更新する。
3. Tier-2（MuJoCo）を geometry.json から組み立て直し、指の開きを実測表に合わせる。
4. **E0' を実施する（30 回）**。挟めた判定のしきい値を読み戻しの分布から決める。

W2：10 月 5 日（月）～ 10 月 11 日（日）—契約・ゲート・記録・採点器

1. 実機側の Actor 契約を、今ある部品の上に実装する：observe は探索、pick は下ろしと挟めた判定、place は置き場への下ろし。結果は型付き（OK, NOT_FOUND, UNREACHABLE, NOT_HELD, TIMEOUT）。要求 ID と期限を付け、**時間切れを成功と扱わない**。
2. 投入ゲート H：関節範囲、卓上の最低高さ、可達帯（14–23 cm）。両条件で有効。
3. 実行履歴を JSONL で残す（時刻、プログラム ID、呼出し、引数、結果、場面の版）。PLAN の列をそのまま使う。
4. 採点器 Y：置き場を撮って色と位置を判定する。**E0 を実施する**。

W3：10 月 12 日（月）～ 10 月 18 日（日）—課題集合と予備実験

1. 課題集合 60 件を六群で確定し、例示用と未見用をプロンプトを書く前に分ける。可達帯の外や三段目を求める指示を群ごとに含める。
2. 予備実験（10 指示）を端から端まで通す。予備のデータは本実験に入れない。

3. 検出力を予備データで引き直し、試行数を確定する。10月18日に計画を凍結する。

W4：10月19日（月）～10月25日（日）—本実験

課題順と条件順を無作為化する。物体と置き場は座標表どおりに毎回戻す。操作者の介入はすべて記録する。条件Aで安全ゲートが止めた試行はAの失敗として数える。

W5：10月26日（月）～11月1日（日）—副次実験と解析

E6を先に、E5は余力があれば。成功率差の信頼区間、McNemar、群別の結果、所要時間の分布、失敗の分類。

W6：11月2日（月）～11月6日（金）—執筆

結果の節を書き、要旨・考察・結論を結果に合わせて改稿する。7.2節のリンク長の記述を直す。機体・制御器・カメラ・グリッパー・シミュレータ・LLMとAIPL処理系の版・寸法表を明記する。

7 リスクと撤退線

E0'で成功率が0.5未満。(1) 挟む指令と高さを読み戻しの分布から選び直す。(2) 立方体を指の開きに合う大きさ(3.5–4cm)に替える。(3) 課題を「押して移動」に変える。いずれも、採用した対処を論文に明記する。

腕の基板が焼き直し後も止まる。自動リセットが原因ではなかったことになる。電源（アダプタの容量）を疑い、別のアダプタで30回を試す。主実験のセッションを短く区切り、止まった試行は「制御器の失敗」として分類して分母に含める。

W2の実装が遅れる。採点器Yを目視判定で代替し、その旨を明記する（E0は不要になる）。主実験の週は動かさない。

効果が小さいとW3で分かる。群を減らして指示数を増やすか、差が小さいことを区間で示す主張に変える。結果を見てから試行数を足さない。

8 先生に決めていただく事項

1. 物体の位置の入力：主実験で、手首カメラによる探索を使うか、座標表の値を入力するか。後者は知覚の誤りを比較から除けるが、論文の射程が狭まる。どちらも両条件で同じ入力にする。
2. Code as Policies 型との比較（論文の副次比較）を残すか。W2–W3の工数では難しい。削るなら主張から外す。
3. Xinuの焼き直し（自動リセットの削除）をW1の初めに行ってよいか。
4. 机上の物：立方体の色と数、置き場の数（現状は青・緑、左右の二つ）。
5. 主実験のセッションに立ち会える日（3時間×7回前後）。

決定事項（2026年9月29日、先生の回答）

1. 物体の位置は手首カメラで探す（座標表の入力は使わない）。両条件で同じ探索を用いる。
2. Code as Policies 型との比較は論文に残す。W2–W3に実装の工数を確保する。
3. Xinuは焼き直す。9月29日に自動リセットの削除とファンの温度追従の復旧を焼いた（Sep 29 2026 09:57:23）。

4. 次の実験では緑と青の 2 つを同時に置き、1 回の実行で両方を運ぶ。
5. 立会いはいつでも可。