

論文①「自然言語から物理動作へ」

完成に向けた実験計画（第 3 版）

法政大学データサイエンスセンター長 児玉靖司

2026 年 9 月 29 日（夕）

要旨

同日昼の改訂版（第 2 版）を、午後の実機実験の結果に合わせて改める。実機は、手首カメラで探した立方体を挟んで色の置き場へ運ぶ作業を、1 個で 2 回、緑と青の 2 個を 1 回の実行で 1 回完遂した。立方体を探す手順は、手の届く帯を決まった順に一巡する方式に改め、挟めたかの判定は指のたわみを踏まえた閾値に直した。一方で、成功率は依然として測っておらず、腕の基板が動作中に止まる原因は特定できていない。本書は、残る 5 週間半（9 月 30 日～11 月 6 日）で主実験（事前選別なし A / あり B の対応比較）を成立させるための実験の並び、合格条件、実機の稼働時間、日程、撤退線を示す。数値のうち実測したものと見積もりは区別して書く。

1 到達点（2026 年 9 月 29 日夕）

表 1: 論文①の研究課題ごとの到達点

項目	状態	論文
RQ1 生成	未見の指示 30 件で予備実験済み（生成プログラム 27 件）	7.1 節
RQ3 検証段	Tier-1（運動学）と Tier-2（MuJoCo）で 27 件。Tier-1 の誤った合格 4 件	7.2 節
RQ2 両実行 実機の作業	同じ手順を模型と実機で実行。応答の欠落、狭い可達域 1 個の振り分けを 2 回、2 個を 1 回の実行で 1 回完遂。模型が見逃した差・判定の誤りを同定	7.3 節 7.4, 7.5 節
RQ4 主実験	未実施	—

主実験の部品として実機で動いているもの。

- 探す（locate）：手の届く帯（土台の軸から 14–23 cm、正面から $\pm 45^\circ$ ）を 2 列 $\times$ 4 か所で一巡し、緑と青の塊を卓上へ逆射影した一覧から選び、カメラを向け直して詰める。一巡に約 54 秒（実測）。
- 下ろす（lower）：指の軸を合わせ、卓上 5 cm から 0.5 cm ずつ、指先 1.2 cm まで。
- 挟めたか（held）：145 で閉じた後の指の読み戻しが 120–141 なら挟んでいる（空 144–145、3 cm を挟むと 139、実測）。
- PLAN：模型・実機・カメラ系の命令を一行に記録（実行履歴の原型）。
- 寸法の一元管理（geometry.json）、Xinu のカーネル（09:57 版、ファン復旧）。

これらは第 2 版で「W2 で作る」とした実機側の Actor 契約の中身にあたる。残るのは、型付きの結果と期限を持つ契約の形に整えることである。

2 未解決の問題と、主実験への影響

1. 成功率が無い。完遂は 1 個で 2 回、2 個で 1 回にすぎず、そのたびに条件を直している。主実験の前に、条件を固定した反復で成功率を測る（E0'）。
2. 腕の基板が動作中に止まる（計 5 回、自動リセットを外した後も 1 回）。止まると電源の入れ直しと Pi 5 の再起動が要り、1 回あたり 5–10 分の中断になる。主実験（250 回前後）の間に止まる回数を測り、原因の候補（電源の容量、サーボの過負荷）を一つずつ除く。

3. 実機の状態を読む判定が負荷の下で誤った（7.5 節）。判定の閾値は、実機の負荷の下で測った分布から決め直し、採点器 Y を含むすべての判定を、目視との一致で検証してから使う（E0）。
4. Tier-2 の模型が実機と合っていない。指の長さ（6 cm vs 推定 8.3 cm）、開き（固定値 vs 7 段の実測）、立方体（3.1 vs 3 cm）、カメラの位置、指のたわみ。Tier-2 の判定が実機を予測するには、これらを実測に合わせる必要がある。
5. 寸法の一部が未実測（指の長さ、カメラの位置と画角、台座）。
6. 1 回の実行に時間がかかる。一巡に 54 秒、2 個の作業で数分。主実験の稼働時間を実測から見積もり直す（第 5 節）。

3 実験の並び（第 3 版）

表 2: 実験の並び。E0' と E0 を主実験の前に置く

	名称	内容	時期
E0'	実機の基礎性能	条件を凍結した sort.aipl で、1 個 20 回・2 個 10 回。完遂率、1 回の所要時間（分布）、指の読み戻しの分布（挟んだ／空）、基板が止まった回数	W1
E0	計器の検証	探索・挟めた判定・採点器 Y が目視と一致するか。成功 15・失敗 15 の場面を意図して作る	W2
E1	主実験 A/B	同一の初回生成プログラムを事前選別なし (A)／あり (B) で対応づけて実機実行	W4
E2	生成の正しさ	60 指示で通過率（予備は 30 件で済み）	W3
E3/E4	却下と誤った合格	E1 のデータから段ごとの却下、誤った却下、誤った合格とその原因	W5
E6	人手確認済み	人手で正しいと確認したプログラムを両バックエンドで実行	W5
E7	CaP 型との比較	同じプリミティブを呼ぶ Python を生成し、同じ試験集合で比較（論文に残すと決定）	W3–W5

E0' の合格条件（結果を見る前に決める）。 1 個の完遂率 ≥ 0.8 （20 回中 16 回以上）、2 個の完遂率 ≥ 0.7 （10 回中 7 回以上）、30 回の間に基板の停止が 1 回以下。満たさなければ、失敗を分類して一つだけ直し、同じ回数をもう一度行う。2 回目も満たさなければ第 7 節の撤退線へ移る。

E0' で凍結する条件。 指の閉じ 145、判定 120–141、指先 1.2 cm、探索 2 列 $\times$ 4 か所、腕の速さ（探索 2.5 s）、立方体 1 辺 3 cm（緑・青）、卓上は白い紙のみ（他の色の物を置かない）、置き場は土台 $150^\circ/30^\circ$ の 17 cm。

4 課題集合（E1, E2, E7）

先生の決定により、物体の位置は手首カメラで探し、机の上には緑と青の立方体を同時に置く。課題は六群のうち、この机上で意味を持つものに絞る。

1. 単一物体の移動（「緑を右へ」）
2. 指定順での移動（「青を先に、次に緑を」）——順序は実行履歴で採点できる
3. 色別の分類（「色で分けて」）
4. 属性による選択（「左にある方を」）——探索の一覧の座標で採点する
5. 積み重ね（「青の上に緑を」）——二段目は可達域内、三段目は届かない（7.3 節）。届かない指示を意図的に含める

6. 解釈の明示が必要な指示——事前規則で明確化または除外

60 指示を群ごとに 10 件とし、例示用と未見用をプロンプトを書く前に分ける。配置は 2 通り（緑と青の左右を入れ替える）。

5 試行数と実機の稼働時間

検出力の計算は変えない（効果 0.25 で 62 件、McNemar 正確検定、検出力 0.8）。60 指示 ×2 配置を計画値とする。

表 3: 実機の実行と稼働時間の見積もり（1 回 5 分は午後の実行からの見積もりで、E0' で実測して引き直す）

実験	実機の実行	時間	備考
E0'	30-60	2.5-5 h	追加の 30 回を含む
E0	30	2.5 h	判定と目視の一致
予備（10 指示 ×2 配置 ×A/B）	≤40	≤3.5 h	本実験に入れない
E1（60 指示 ×2 配置）	A 120 + B ≤120	≤20 h	配置の戻しを含まない
E7（CaP 型、同じ試験集合の一部）	≤40	≤3.5 h	範囲は W3 で決める
計	≤290	≤35 h	3 時間のセッション 12 回前後

第 2 版の見積もり（1 回 3 分、計 18.5 時間）は、探索の一巡（54 秒）と腕を遅くしたことを含んでいなかった。時間が足りない場合は、探索を「前回の一覧から始めて、見つからなければ一巡」に短縮する（主実験の前に凍結）。

6 日程（9 月 30 日～ 11 月 6 日）

W1：9 月 30 日（火）～ 10 月 4 日（日）—条件を凍結し、基礎性能を測る

1. 寸法を物差しで測る（指の長さ、手首からカメラ、指の軸からカメラ、台座）。画角は既知の大きさの立方体を既知の距離で撮って求める。
2. E0'（1 個 20 回・2 個 10 回）。所要時間、読み戻しの分布、基板の停止を記録する。
3. 基板の停止：別のアダプタ（容量の大きいもの）で同じ回数を行い、停止の頻度を比べる。

W2：10 月 5 日（月）～ 10 月 11 日（日）—契約・ゲート・記録・採点器

1. 実機側の Actor 契約：observe（探索の一覧）、pick(color)、place(zone)、stack(on)。結果は型付き（OK, NOT_FOUND, UNREACHABLE, NOT_HELD, DROPPED, TIMEOUT）、要求 ID と期限つき。時間切れを成功と扱わない。
2. 投入ゲート H（関節範囲、指先の最低高さ、可達帯）。両条件で有効。
3. 実行履歴（JSONL）：PLAN の列をそのまま保存する。
4. 採点器 Y：置き場と積み重ね位置を撮り、色と位置を判定する。E0 で目視と一致させる。
5. Tier-2（MuJoCo）を geometry.json から組み直す（指の長さ・開きの実測表・立方体 3 cm・カメラ位置・指のたわみ）。

W3：10 月 12 日（月）～ 10 月 18 日（日）—課題集合・生成・予備実験

1. 課題集合 60 件を確定し分割する。LLM から AIPL と CaP 型 Python の両方を生成する（E2, E7）。
2. 予備実験（10 指示）を端から端まで通す。予備のデータは本実験に入れない。
3. 検出力を引き直し、10 月 18 日に計画を凍結する。

W4：10 月 19 日（月）～ 10 月 25 日（日）—本実験（E1）

課題順と条件順を無作為化する。配置は毎回同じ手順で戻す。操作者の介入と基板の停止をすべて記録する。条件 A で安全ゲートが止めた試行は A の失敗として数える。

W5：10 月 26 日（月）～ 11 月 1 日（日）—副次実験（E6, E7）と解析

成功率差の信頼区間（指示単位のクラス・ブートストラップ）、McNemar、群別の結果、所要時間の分布、失敗の分類。

W6：11 月 2 日（月）～ 11 月 6 日（金）—執筆

結果の節、要旨・考察・結論の改稿。7.2 節のリンク長の記述を直す。版と寸法表を明記する。

7 リスクと撤退線

E0' を 2 回とも満たさない。 (1) 立方体を指の開きに合う大きさ（3.5–4 cm）に替える。(2) 課題から積み重ねを外す。(3) 課題を「押して移動」に変える。採用した対処を論文に明記する。

基板の停止が減らない。 セッションを短く区切り、止まった試行は「制御器の失敗」として分母に含める。停止の頻度そのものを結果として報告する。

稼働時間が足りない。 配置を 1 通りに減らす前に、探索の短縮（前回の一覧から始める）を試す。結果を見てから試行数を足さない。

CaP 型の比較が実装できない。 比較の主張を論文から削る（第 2 版の方針のとおり）。ただし先生の決定により、W3–W5 に工数を確保して実装を試みる。

8 次に先生に確かめること

1. 容量の大きい腕用アダプタの有無（基板の停止の切り分け）。
2. 積み重ねの課題（二段目）を課題集合に含めてよいか。
3. E0' の合格条件（1 個 0.8、2 個 0.7）でよいか。